

# 第二周

《高等概率论》  
《高等统计学》  
《统计机器学习》

概率论 → 研究随机性，减少不确定性给决策带来的困难

## 第二周

Chapter 1

Chapter 2

课程设置：

1. 极大似然估计 → 证明方法（优化方法引进）
2. 渐进有效估计
3. 交换方法 → 给一类估计量算...，只用一个公式
4. 总体分布的估计
5. 非参数回归系数的局部常数和局部线性统计
6. 分位数估计与Bahadur表示
7. M-估计
8. Jackknife 1
9. Jackknife 2
10. Bootstrap
11. 多重检验
12. 统计机器学习方法

## Chapter 1

模型 → 机器学习三要素之一

概率模型  $\begin{cases} \text{参数模型} & \text{分布确定，参数不确定} & \text{能用有限个参数来确定 } \mathbf{Y} \text{ 的分布} & \text{可识别性} \\ \text{非参数模型} \end{cases}$

**可识别性：**分布确定，则参数就确定下来

例  $N(\mu, \sigma^2)$  参数为  $(\mu, \sigma^2)$

$$\begin{aligned} \mu &= 0 \\ \sigma^2 &= 1 \end{aligned}$$

则标准正态分布  $\mu = 1, \sigma^2 = 1$  唯一确定

若参数为  $(\mu, \sigma)$

则标准正态分布  $\mu = 1, \sigma = \pm 1$  不唯一确定

对于指数分布  $\varepsilon(\lambda\mu) = \varepsilon(\eta)$

以  $\eta$  为参数的指数分布 → 可识别

以 $(\lambda, \mu)$  为参数的指数分布  $\rightarrow$  不可识别

**可识别性**：若  $\theta_1 \neq \theta_2$  , 则  $F_{\theta_1} \neq F_{\theta_2}$

不能确定参数, 则不好解释, 则一般要求参数模型可识别; 若不能识别, 则加限制条件, 去掉冗余, 使之可识别

### 非参数模型

例如:

- 所有连续分布
- 所有对称分布

有很多的可能性, 不能确定某一类, 则要考虑一个很大的非参模型

子集

$\Downarrow$

**半参数模型**：一部分特征可以参数化

例: 线性模型  $Y = X^T \beta + \varepsilon$   $E(\varepsilon) = 0$   $Var(\varepsilon) < +\infty$

$Y$  为响应变量

则 $Y$  的分布  $F(X^T \beta, \sigma^2)$  为一类分布, 不知道其具体的, 但知道其均值方差

优缺点:

参数模型:

- 优点: 简单
- 缺点: 可能犯模型设定错误

非参数模型:

- 稳健  $\Rightarrow$  神经网络
- 难算

# 指数分布族

$$f_{\theta}(X) = \exp \left\{ \sum_{j=1}^k \eta_j(\theta) T_j(X) - B(\theta) \right\} h(x)$$

参数根统计量可分离  $\Rightarrow$  充分统计量  $\rightarrow$  完备统计量  $\rightarrow$  数据压缩 (最好用不超过参数个数的统计量)

$$B(\theta) = \ln \{ \dots \}$$

自由的是  $\eta_1(\theta), \dots, \eta_k(\theta)$ , 确定之后  $B(\theta)$  随之确定

## Canonical form

$$f_{\eta}(X) = \exp \left\{ \sum \eta_j T_j(X) - A(\eta) \right\} h(X)$$

参数变为  $\eta$

例:  $X \sim N(\mu, \sigma^2)$       $\theta = (\mu, \sigma^2)$

$$\begin{aligned} f_{\theta}(X) &= \frac{1}{\sqrt{2\pi}\sqrt{\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} \\ &\doteq \exp \left\{ -\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2} \right\} - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log \sigma^2 \\ &\quad \text{后面的部分移入 } B(\theta) \text{ 或 } H(x) \\ &\doteq \exp \left\{ -\frac{1}{2} \frac{x^2 - 2\mu x + \mu^2}{\sigma^2} \right\} \\ &= \exp \left\{ -\frac{1}{2} \frac{1}{\sigma^2} \cdot x^2 + \frac{\mu}{\sigma^2} \cdot x - \frac{1}{2} \frac{1}{\sigma^2} \mu^2 \right\} \\ &\quad \text{最后一项移入 } B(\theta) \\ &\doteq \exp \left\{ -\frac{1}{2} \frac{1}{\sigma^2} \cdot x^2 + \frac{\mu}{\sigma^2} x \right\} \\ &\doteq \exp \{ \eta_1(\theta) x^2 + \eta_2(\theta) x \} \end{aligned}$$

$$\eta = (\eta_1, \eta_2)$$

$$(\mu, \sigma^2) \mapsto (\eta_1, \eta_2)$$

$$f_{\eta}(x) = \exp \{ \eta_1 x^2 + \eta_2 x \} \dots$$

### D 1.1.4 Ex ... of full rank

- $T, \eta$  都不是满足一个线性约束
- 参数空间包含  $k$  维矩形

$$\text{例子: } f_{\eta}(X) = \exp \{ \eta_1 x^2 + \eta_2 x \}$$

### Ex 1.1.3 $X_1, \dots, X_n \sim N(\mu, \theta^2)$ 不是 full rank

参数空间  $\eta_{\theta} = (\frac{1}{\theta}, -\frac{1}{2\theta^2})$  不包含一个长方形

### 1.1.2 指数分布具有封闭性

- $X$  是  $k$  参数指数分布
- $Y$  是  $k$  参数指数分布

- $X, Y$  独立

$\Rightarrow (X, Y)$  仍然是  $k$  参数指数分布

1.1.3  $X$  是  $k$  参数指数分布, 则其  $k$  个统计量的分布函数  $T = (T_1(x), \dots, T_k(x))$

$f_T(t) = \dots = \exp\{\sum \eta_j(\theta)t_j - B(\theta)\}h_\theta(t)$  不是  $k$  参数指数分布

1.1.4  $T(x)$  的各界矩  $\rightarrow$  只跟  $A(\eta)$  有关系

m.g.f 矩母函数  $M(s) = \exp\{A(s + \eta) - A(\eta)\}$

**矩母函数**  $M(s) = Ee^{s \cdot Y} = \int e^{s \cdot Y} f(y) dy < \infty$

若  $s = it$ , 则转化为特征函数,  $s \cdot Y$  为内积

可以求导来算  $Y$  的矩

$$E(Y) = M'(s)|_{s=0} = (EY e^{s \cdot Y})|_{s=0}$$

$$Var(Y) = E(Y^2) - (EY)^2$$

**Ber(p) 伯努利分布**  $x = \begin{cases} 1 & p \\ 0 & 1-p \end{cases}$

$$f_p(x) = p^x (1-p)^{1-x} = \exp\{x \ln p + (1-x) \ln(1-p)\}$$

$$= \exp\left\{x \ln \frac{p}{1-p} + \ln(1-p)\right\}$$

$$\eta = \ln \frac{p}{1-p} \rightarrow p = \frac{e^\eta}{1+e^\eta} = \exp\{x \cdot \eta - \ln(1+e^\eta)\}$$

$$= \exp\{x \cdot \eta - A(\eta)\}$$

$$p = EX = E(T(x)) = A'(\eta) = \frac{e^\eta}{1+e^\eta} = \frac{e^{x^T \beta}}{1+e^{x^T \beta}}$$

其中,  $A'(\eta) = \frac{e^\eta}{1+e^\eta}$  是连接函数

$Y \quad EY = X^T \beta$  线性模型  $\rightarrow$  逻辑回归

- 两点分布对于逻辑回归
- 泊松分布对于泊松回归  $\rightarrow$  指数分布族

参数与统计量分不开的反例  $[0, \theta]$  上的均匀分布

不可能写成指数分布

$$X \sim U(0, \theta) \quad f_\theta(x) = \frac{1}{\theta} I_{0 < x < \theta} \quad \neq \eta(\theta) \cdot T(X)$$

最大次序统计量

尺度变换族

## Chapter 2

1. 依分布收敛  $X_n \rightarrow^d X$   $F_n(x) = P(X_n \leq x) \rightarrow P(X \leq x) = F(X) \quad n \rightarrow \infty$
2. 依概率收敛  $X_n \rightarrow^p X$   $\forall \varepsilon > 0. \quad P\{|X_n - X| > \varepsilon\} \rightarrow 0 \quad n \rightarrow \infty$
3. 几乎必然收敛  $X_n \rightarrow^{a.s.} X$   $\forall \varepsilon > 0 \quad \forall n > 0 \quad p\{\cup_{k \geq n} [|X_k - X| > \varepsilon]\} \rightarrow 0$
4. Lr 收敛  $X_n \rightarrow^{lr} X$   $E|X_n - X|^r \rightarrow 0$

这几个收敛的关系 (推导写作作业)

- $3 \Rightarrow 2$
- $4 \Rightarrow 2$  马尔可夫不等式  $P\{|X_n - X| > \varepsilon\} \leq \frac{E|X_n - X|^r}{\varepsilon^r}$
- $2 \Rightarrow 1$
- 若  $X = c$  为常数, 则  $1 \Rightarrow 2$

解答：

- 依概率收敛  $\rightarrow$  依分布收敛

依概率收敛：

$$X_n \xrightarrow{p} X \quad \forall \epsilon > 0 \quad P\{|X_n - X| > \epsilon\} \rightarrow 0 \quad n \rightarrow \infty$$

依分布收敛：

$$X_n \xrightarrow{d} X \quad F_n(x) = P\{X_n \leq x\} \rightarrow P\{X \leq x\} = F(x) \quad n \rightarrow \infty$$

证明：

设随机变量的分布函数为  $F(x), F_1(x), F_2(x), \dots$

令  $x' < x$ ，则

$$\begin{aligned} \{X \leq x'\} &= \{X_n \leq x, X \leq x'\} \cup \{X_n > x, X \leq x'\} \\ &\subset \{X_n \leq x\} \cup \{|X_n - X| \geq x - x'\} \end{aligned}$$

由  $X_n \xrightarrow{p} X$ ，有  $P\{|X_n - X| \geq x - x'\} \rightarrow 0 \quad n \rightarrow \infty$

所以  $F(x') \leq \lim_{n \rightarrow \infty} F_n(x)$

再令  $x' \rightarrow x$ ，即可得  $F(x-0) = \lim_{x' \rightarrow x^-} F(x') \leq F_n(x)$

同理可得，当  $x'' > x$  时，有  $\lim_{n \rightarrow \infty} F_n(x) \leq F(x'')$

令  $x'' \rightarrow x$ ，即得  $\lim_{n \rightarrow \infty} F_n(x) \leq F(x+0)$

所以，对所有的  $x$ ，有

$$F(x-0) \leq \lim_{n \rightarrow \infty} F_n(x) \leq F(x+0)$$

当  $x$  是  $F(x)$  的连续点时，有  $F(x-0) = F(x+0)$ ，定理得证

- 若  $x = c$  是常数, 则 依分布收敛  $\rightarrow$  依概率收敛

依分布收敛:

$$X_n \rightarrow^d X \quad F_n(x) = P\{X_n \leq x\} \rightarrow P\{X \leq x\} = F(x) \quad n \rightarrow \infty$$

依概率收敛:

$$X_n \rightarrow^p X \quad \forall \epsilon > 0 \quad P\{|X_n - X| > \epsilon\} \rightarrow 0 \quad n \rightarrow \infty$$

证明:

记  $X_n$  的分布函数为  $F_n(x)$   $n = 1, 2, \dots$

常数  $c$  的分布函数为退化分布

$$F(x) = \begin{cases} 0 & x < c \\ 1 & x \geq c \end{cases}$$

对任意的  $\epsilon > 0$ , 有

$$\begin{aligned} P\{|X_n - c| \geq \epsilon\} &= P\{X_n \geq c + \epsilon\} + P\{X_n \leq c - \epsilon\} \\ &\leq P\{X_n > c + \epsilon/2\} + P\{X_n \leq c - \epsilon\} \\ &= 1 - F_n(c + \epsilon/2) + F_n(c - \epsilon) \end{aligned}$$

由于  $x = c + \epsilon/2$  和  $x = c - \epsilon$  均为  $F(x)$  的连续点, 且  $F_n(x) \rightarrow^d F(x)$

所以当  $n \rightarrow \infty$  时, 有

$$F_n(c + \epsilon/2) \rightarrow F(c + \epsilon/2) = 1 \quad F_n(c - \epsilon) \rightarrow F(c - \epsilon) = 0$$

由此可得

$$P\{|X_n - c| \geq \epsilon\} \rightarrow 0$$

定理得证

- 几乎必然收敛  $\rightarrow$  依概率收敛

几乎必然收敛:

$$X_n \xrightarrow{a.s.} X \quad \forall \epsilon > 0 \quad \forall n > 0 \quad P(\cup_{k \geq n} \{|X_k - X| > \epsilon\}) \rightarrow 0$$

依概率收敛:

$$X_n \xrightarrow{P} X \quad \forall \epsilon > 0 \quad P\{|X_n - X| > \epsilon\} \rightarrow 0 \quad n \rightarrow \infty$$

任取一个正实数  $\epsilon > 0$

$$A_n = \cup_{k \geq n} \{x : |X_k(x) - X(x)| > \epsilon\}$$

因为  $A_{n+1} \subseteq A_n$  , 所以  $A_\infty = \cap_{n \geq 1} A_n$

令  $O = \{x : \lim_{n \rightarrow \infty} X_n(x) = X(x)\}$

因为几乎必然收敛  $P(O) = 1$

对于  $O$  中任意元素  $x$  , 能找到一个正整数  $N$  , 使得当  $n > N$  时, 有

$$|X_n(x) - X(x)| < \epsilon$$

则  $O$  中任意元素不属于  $A_\infty$

所以  $P(A_\infty) < P(\overline{O}) = 0$

$$P\{|X_n - X| > \epsilon\} < P(A_n) \rightarrow 0$$

定理得证



- Lr收敛 → 依概率收敛

Lr收敛:

$$X_n \xrightarrow{L^r} X \quad E |X_n - X|^r \rightarrow 0 \quad n \rightarrow \infty$$

依概率收敛:

$$X_n \xrightarrow{P} X \quad \forall \epsilon > 0 \quad P\{|X_n - X| > \epsilon\} \rightarrow 0 \quad n \rightarrow \infty$$

证明:

由Chebyshev不等式:

$$\forall \epsilon > 0 \quad P\{|X_n - X| > \epsilon\} \leq \frac{E |X_n - X|^r}{\epsilon^r}$$

$$\begin{aligned} P\{|X_n - X| > \epsilon\} &= \int_{|X_n - X| > \epsilon} dF(x) \\ &\leq \int_{|X_n - X| > \epsilon} \frac{|X_n - X|^r}{\epsilon^r} dF(x) \\ &= \frac{1}{\epsilon^r} \int_{|X_n - X| > \epsilon} |X_n - X|^r dF(x) \\ &= \frac{1}{\epsilon^r} E |X_n - X|^r \end{aligned}$$

可得:

$$\begin{aligned} P\{|X_n - X| > \epsilon\} &\leq \frac{E |X_n - X|^r}{\epsilon^r} \\ &= \frac{1}{\epsilon^r} E |X_n - X|^r \\ &\xrightarrow{\text{由Lr收敛}} 0 \quad n \rightarrow \infty \end{aligned}$$

定理可证